

# Análise de credibilidade dos dados de fornecedores

Aqui eu olho a qualidade do cadastro em quatro pontos:

1. **Compleitude** — se todo fornecedor tem CNPJ ou CPF
2. **Unicidade** — CNPJ repetido e gente com CNPJ e CPF no mesmo registro
3. **Consistência** — se a UF existe na base de municípios
4. **Similaridade** — se a descrição do CNAE bate com a tabela da Receita (e o quão diferente ela é, via Levenshtein)

## 1. Imports

## 2. Lendo as bases

Os arquivos estão em `data/Dados` : fornecedores, municípios, CNAE interno e o CSV da RFB.

### BASES CARREGADAS

**15.734**

FORNECEDORES

15 colunas

**5.584**

MUNICÍPIOS

6 colunas

**1.348**

CNAE INTERNO

3 colunas

**1.359**

CNAE RFB

2 colunas

### COLUNAS DOS FORNECEDORES

id

cnpj

cpf

nome

ativo

recadastrado

id\_municipio

uf

id\_natureza\_juridica

id\_porte\_empresa

id\_ramo\_negocio

id\_unidade\_cadastradora

id\_cnae

id\_cnae2

habilitado\_licitar

ESQUEMA DE FORNECEDORES

| COLUNA                  | TIPO    | PREENCHIDOS |
|-------------------------|---------|-------------|
| id                      | int64   | 15734       |
| cnpj                    | object  | 13410       |
| cpf                     | object  | 2324        |
| nome                    | object  | 15734       |
| ativo                   | bool    | 15734       |
| recadastrado            | object  | 0           |
| id_municipio            | int64   | 15734       |
| uf                      | object  | 15734       |
| id_natureza_juridica    | float64 | 13393       |
| id_porte_empresa        | float64 | 15710       |
| id_ramo_negocio         | object  | 0           |
| id_unidade_cadastradora | object  | 0           |

## AMOSTRA DE FORNECEDORES

| ID   | CNPJ           | CPF          | NOMI                                                        | ATIVC | RECA | ID_M | UF | ID_N/ | ID_PC | ID_RA | ID_UF | ID_CN     | ID_CN | HABI |
|------|----------------|--------------|-------------------------------------------------------------|-------|------|------|----|-------|-------|-------|-------|-----------|-------|------|
| 498  | —              | ***635939010 | RODRIGO<br>SILVEIRA                                         | True  | —    | 35   | RO | —     | 1.0   | —     | —     | —         | —     | True |
| 2597 | 00265426600170 | —            | CONCRETA<br>ENGENHARIA<br>E<br>CONSTRUÇOES<br>LTDA          | True  | —    | 35   | RO | 2.0   | 2.0   | —     | —     | 4120400-0 | —     | True |
| 3519 | 00351475000120 | —            | PELUFIL<br>COM<br>DE<br>PECAS<br>E<br>LUBRIFICANTES<br>LTDA | False | —    | 94   | RO | 2.0   | 2.0   | —     | —     | 4732600-0 | —     | True |
| 4603 | 00449404900167 | —            | EXRUMA<br>COMERCIO<br>E<br>SERVICOS<br>LTDA                 | False | —    | 35   | RO | 2.0   | 2.0   | —     | —     | 4751201-0 | —     | True |
| 4605 | 00449484000160 | —            | COMERCIO                                                    | True  | —    | 132  | RO | 2.0   | 2.0   | —     | —     | 4681802-0 | —     | True |

mostrando 5 de 15734

## 3. Completude

Todo fornecedor precisa ter CNPJ ou CPF. Se os dois campos vierem vazios, o registro não passa.

### COMPLETUDE

15.734

FORNECEDORES

0

SEM DOCUMENTO

100.00%

COMPLETUDE

#### TAXA DE COMPLETUDE

quem tem CNPJ ou CPF preenchido



100.00%

#### COMPLETUDE

ninguém ficou sem documento

## 4. Unicidade

Duas checagens: se o mesmo CNPJ aparece em mais de um fornecedor, e se algum registro tem CNPJ e CPF juntos (PF e PJ no mesmo cadastro).

#### UNICIDADE

0

CNPJ DUPLICADO

0

CNPJ + CPF JUNTOS

#### CNPJ DUPLICADO

não achei o mesmo CNPJ em mais de um fornecedor

#### PF / PJ

ninguém misturou CNPJ e CPF no mesmo cadastro

## 5. Consistência de UF

A UF do fornecedor tem que existir na base de municípios. Qualquer sigla fora dessa lista (ou nula) eu marco como inconsistente.

### CONSISTÊNCIA DE UF

27

UFS DE REFERÊNCIA

0

UF ESTRANHA

100.00%

CONFORMIDADE

### UFS DA BASE DE MUNICÍPIOS

AC

AL

AM

AP

BA

CE

DF

ES

GO

MA

MG

MS

MT

PA

PB

PE

PI

PR

RJ

RN

RO

RR

RS

SC

SE

SP

TO

### CONFORMIDADE DA UF

fornecedores cuja UF existe na tabela de municípios

100.00%

## 6. CNAE — bate com a Receita?

Cruzo o CNAE interno com o CSV da RFB pelo código e vejo se a descrição é a mesma. O CSV não tem cabeçalho, então a primeira linha já é dado.

### CNAE VS RECEITA

1348

INTERNO

1359

TABELA RFB

1348

DEU MATCH

0

SEM PAR NA RFB

1207

TEXTOS DIFERENTES

### QUANTO DO CNAE INTERNO DIVERGE

mesmo código, descrição diferente da RFB

89.54%

### AMOSTRA DAS DESCRIÇÕES DIFERENTES

| CODIGO_CNAE | DESCRICAO_FORNECEDOR                                                                            | DESCRICAO_RFB                                                                             |
|-------------|-------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| 0111399     | CULTIVO DE OUTROS CEREAIS<br>NAO ESPECIFICADOS<br>ANTERIORMENTE                                 | Cultivo de outros cereais não<br>especificados anteriormente                              |
| 0112101     | CULTIVO DE ALGODAO<br>HERBACEO                                                                  | Cultivo de algodão herbáceo                                                               |
| 0112199     | CULTIVO DE OUTRAS FIBRAS DE<br>LAVOURA TEMPORARIA NAO<br>ESPECIFICADAS<br>ANTERIORMENTE         | Cultivo de outras fibras de<br>lavoura temporária não<br>especificadas anteriormente      |
| 0113000     | CULTIVO DE CANA-DE-ACUCAR                                                                       | Cultivo de cana-de-açúcar                                                                 |
| 0116499     | CULTIVO DE OUTRAS<br>OLEAGINOSAS DE LAVOURA<br>TEMPORARIA NAO<br>ESPECIFICADAS<br>ANTERIORMENTE | Cultivo de outras oleaginosas de<br>lavoura temporária não<br>especificadas anteriormente |
| 0119905     | CULTIVO DE FEIJAO                                                                               | Cultivo de feijão                                                                         |
| 0119907     | CULTIVO DE MELAO                                                                                | Cultivo de melão                                                                          |
| 0119999     | CULTIVO DE OUTRAS PLANTAS                                                                       | Cultivo de outras plantas                                                                 |

mostrando 10 de 1207

## 7. Distância de Levenshtein

Nos CNAEs que não bateram, calculo quantas edições separam as duas descrições e transformo isso numa similaridade de 0 a 100%. Comparo em maiúsculo pra não inflar a distância só por causa de caixa.

## LEVENSHTEIN

1207

CÓDIGOS

93.86%

SIMILARIDADE MÉDIA

60.34%

MÍNIMA

33

MAIOR DISTÂNCIA

## SIMILARIDADE MÉDIA

média do grau de similaridade nas descrições que divergiram



93.86%

### PIORES DIVERGÊNCIAS (MAIOR DISTÂNCIA)

| CODIGO_CNAE | DESCRICAO_FORNEC                                                                                                                                                | DESCRICAO_RFB                                                                                                                                          | DISTANCIA_LEVENS | GRAU_SIMILARIDADE |
|-------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|------------------|-------------------|
| 8720499     | ATIVIDADES DE ASSISTENCIA PSICOSSOCIAL E A SAUDE A PORTADORES DE DISTURBIOS PSIQUICOS, DEFICIENCIA MENTAL E DEPENDENCIA QUIMICA NAO ESPECIFICADAS ANTERIORMENTE | Atividades de assistência psicossocial e à saúde a portadores de distúrbios psíquicos, deficiência mental e dependência química e grupos similares não | 33               | 79.25             |
| 1741902     | FABRICACAO DE PRODUTOS DE PAPEL, CARTOLINA, PAPEL-CARTAO E PAPELÃO ONDULADO PARA USO COMERCIAL E DE ESCRITORIO                                                  | Fabricação de produtos de papel, cartolina, papel cartão e papelão ondulado para uso comercial e de escritório, exceto formulário contínuo             | 33               | 76.09             |

mostrando 12 de 1207

## 8. O que eu achei

No cadastro em si a base está ok: os 15.734 fornecedores têm documento, não achei CNPJ duplicado nem PF/PJ misturado, e as UFs fecham 100% com a tabela de municípios.

O buraco é o CNAE. Dos 1.348 códigos internos, 1.207 têm texto diferente da Receita. Na prática é acento e grafia ( `ALGODAO` vs `algodão` ); a similaridade média ficou em 93,86%. Mesmo assim, a descrição oficial deveria ser a referência.

A célula de baixo só junta os números pra não ficar caçando print nas seções.

## RESUMO

15.734

FORNECEDORES

100.00%

COMPLETUDE

0 sem documento

0

CNPJ DUPLICADO

0

CNPJ + CPF

100.00%

UF OK

1207

CNAE DIFERENTE

1348 comparados

## SIMILARIDADE MÉDIA DO CNAE

as descrições quase só mudam acento e grafia, mas ainda assim não são iguais



93.86%

TOP 5 MAIS DISTANTES

| CODIGO_CNAE | DESCRICAO_FORNE                                                                                                                                                 | DESCRICAO_RFB                                                                                                                                          | DISTANCIA_LEVENS | GRAU_SIMILARIDADE |
|-------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|------------------|-------------------|
| 8720499     | ATIVIDADES DE ASSISTENCIA PSICOSSOCIAL E A SAUDE A PORTADORES DE DISTURBIOS PSIQUICOS, DEFICIENCIA MENTAL E DEPENDENCIA QUIMICA NAO ESPECIFICADAS ANTERIORMENTE | Atividades de assistência psicossocial e à saúde a portadores de distúrbios psíquicos, deficiência mental e dependência química e grupos similares não | 33               | 79.25             |
| 1741902     | FABRICACAO DE PRODUTOS DE PAPEL, CARTOLINA, PAPEL-CARTAO E PAPELAO ONDULADO PARA USO COMERCIAL E DE ESCRITORIO                                                  | Fabricação de produtos de papel, cartolina, papel cartão e papelão ondulado para uso comercial e de escritório, exceto formulário contínuo             | 33               | 76.09             |

mostrando 5 de 1207